

Aula 9

Classificação e Regras de Classificação

Introdução

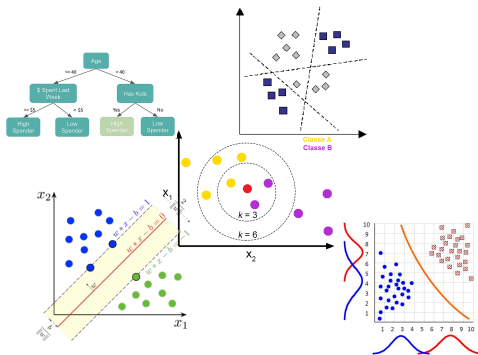
- Um **modelo de classificação** é geralmente gerado por métodos de aprendizado (semis)**supervisionados** e seu objetivo é **predizer um valor categórico de um atributo alvo**
- Portanto, a classificação pertence à categoria de **modelos preditivos**
- Porém, é diferente dos modelos de regressão cujo objetivo é prever um valor numérico
- A **construção de um modelo de classificação** se dá por meio de **observações passadas** e **seus valores atributos alvo (categoria)**

Finalidades

- A classificação por ser utilizada em sistemas de apoio a tomada de decisão para diferentes finalidades
 - Seleção de potenciais consumidores
 - Detecção de fraudes
 - Diagnósticos médicos (precocemente)
 - Redirecionamento de e-mails
 - Retenção de clientes
 - ...

Introdução

- O modelo de classificação irá gerar um conjunto de **regras**, hiperplanos ou algum outro mecanismo para prever o valor categórico atributo alvo de exemplos futuros



Introdução

- Apesar das diferentes possibilidades de se induzir um modelo de classificação, nesta aula iremos estudar a **classificação baseada em regras**

Exemplo de Regras de Classificação

| | |
|---------|---|
| r_1 : | $(\text{Gives Birth} = \text{no}) \wedge (\text{Aerial Creature} = \text{yes}) \longrightarrow \text{Birds}$ |
| r_2 : | $(\text{Gives Birth} = \text{no}) \wedge (\text{Aquatic Creature} = \text{yes}) \longrightarrow \text{Fishes}$ |
| r_3 : | $(\text{Gives Birth} = \text{yes}) \wedge (\text{Body Temperature} = \text{warm-blooded}) \longrightarrow \text{Mammals}$ |
| r_4 : | $(\text{Gives Birth} = \text{no}) \wedge (\text{Aerial Creature} = \text{no}) \longrightarrow \text{Reptiles}$ |
| r_5 : | $(\text{Aquatic Creature} = \text{semi}) \longrightarrow \text{Amphibians}$ |

[Tan et al., 2019]

- Os algoritmos de aprendizado baseados em regras pertencem ao **paradigma de aprendizado simbólico** \rightarrow **modelo/conhecimento facilmente interpretável**

Fases da Classificação

- O desenvolvimento e aplicação de um modelo de classificação consiste em 3 fases principais:

1 **Treinamento**


2 **Teste**

3 **Predição**


Fases da Classificação

- O desenvolvimento e aplicação de um modelo de classificação consiste em 3 fases principais
 - **Treinamento:** nesta fase é aplicado um algoritmo de aprendizado que irá aprender as classes de um exemplo com base nos exemplos e seus respectivos rótulos


Fases da Classificação: Treinamento



Fases da Classificação: Treinamento



Fases da Classificação: Treinamento




Modelo de Classificação

Fases da Classificação

- O desenvolvimento e aplicação de um modelo de classificação consiste em 3 fases principais:
 - **Teste:** na fase de teste, as regras geradas durante a fase de treinamento são usadas para classificar exemplos (geralmente não considerados durante a fase de treinamento) para medir o desempenho do classificador (o quanto ele acerta as classificações).

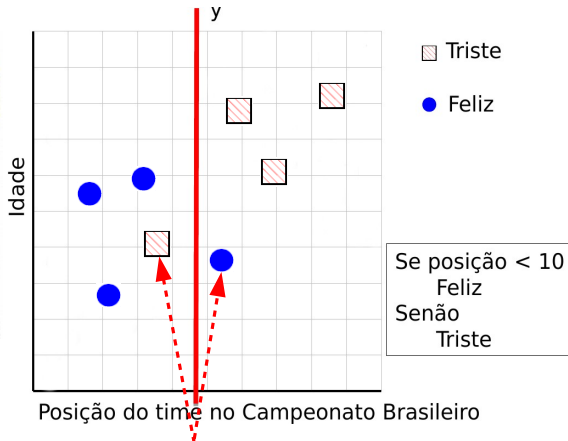
Fases da Classificação: Teste



Fases da Classificação: Teste



**Taxa de Acerto
de 75%**





Exemplos Classificados Erroneamente



Fases da Classificação

- O desenvolvimento e aplicação de um modelo de classificação consiste em 3 fases principais:
 - **Predição**
 - Esta fase representa o uso do modelo de classificação na prática
 - A predição é obtida com as regras do modelo de classificação
 - A diferença da fase anterior é que nesta fase, os exemplos submetidos não possuem rótulos para serem comparados com os rótulos preditos

Fases da Classificação: Predição



Fases da Classificação: Predição




Discretização

- Vale lembrar que mesmo se o atributo alvo for um atributo numérico, pode-se aplicar a classificação
- Porém, será necessário a **discretização do atributo alvo** → transformar os valores de um atributo numérico para valores categóricos
- O procedimento básico para discretização é definir intervalos de valores (ex: $[0-1,50]$) de forma que todo valor de atributo que esteja dentro desse intervalo, será substituído pelo rótulo do intervalo

Discretização

- A discretização pode ser feita de maneira manual ou automática
- No caso da discretização manual, um especialista define o tamanho dos intervalos bem como o rótulo de cada intervalo:



Discretização

- No caso da discretização automática, essa pode ser feita de maneira supervisionada ou não supervisionada
- No caso da supervisionada, é necessário ter o atributo alvo, de forma a utilizar alguma medida de pureza entre um conjunto de valores e a classe
- Essas medidas já foram (ou serão) vistas na disciplina de Inteligência Artificial (ex: Entropia, Ganho de Informação, e Gini Index)

Discretização

- Já os métodos de discretização não supervisionados analisam somente os valores do atributo a ser discretizado → podem ser aplicados em qualquer situação
- Métodos de discretização automáticos e não supervisionados mais comuns:
 - **Intervalos iguais:** os intervalos são uniformes, isto é são criados de forma que todos os mesmos tamanho
 - **Frequências iguais:** intervalos são criados de forma que cada um cubra o mesmo número de valores
 - **Agrupamento de dados:** agrupa os valores dos atributos de forma que valores dentro do mesmo grupo sejam mais próximos entre si do que valores de grupos diferentes


Discretização por Intervalos Iguais

Valores Originais

| Nível de Stress |
|-----------------|
| 18 |
| 9 |
| 15 |
| 12 |
| 38 |
| 5 |
| 19 |
| 45 |
| 26 |
| 14 |
| 42 |
| 21 |



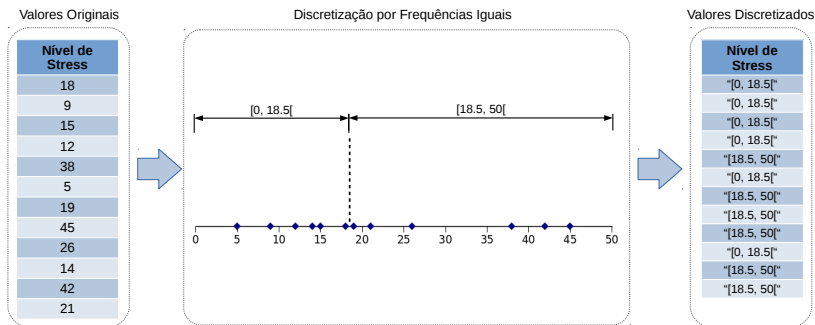
Discretização por Intervalos Iguais




Valores Discretizados

| Nível de Stress |
|-----------------|
| "[0, 25[" |
| "[0, 25[" |
| "[0, 25[" |
| "[0, 25[" |
| "[25, 50]" |
| "[0, 25[" |
| "[0, 25[" |
| "[25, 50]" |
| "[25, 50]" |
| "[0, 25[" |
| "[25, 50]" |
| "[0, 25[" |

Discretização por Frequências Iguais



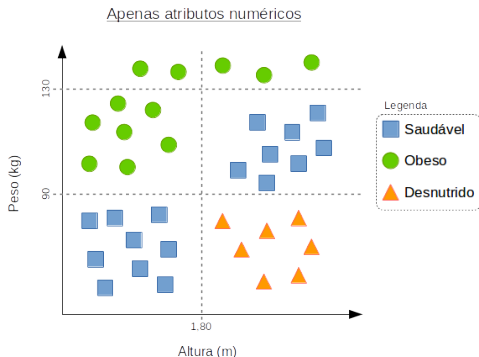
Discretização por Agrupamento de Dados



Regras de Classificação

- Regras são uma boa forma de representar conhecimento
- Regras de classificação pertencem ao **paradigma simbólico**
→ facilmente interpretáveis
- A classificação baseada em regras faz uso de um conjunto de regras do tipo SE-ENTÃO para executar a classificação
SE tempo = ensolarado ENTÃO jogar = sim
- O antecedente da regra (correspondente ao SE) pode ter mais de um teste
SE tempo = ensolarado & umidade = normal ENTÃO
jogar = yes


Interpretação das Regras de Classificação no Espaço



Regras

- Se $\text{Peso} > 130$ Então Obeso
- Se $\text{Altura} < 1.80$ E $\text{Peso} > 90$ Então Obeso
- Se $\text{Altura} > 1.80$ E $\text{Peso} > 90$ Então Saudável
- Se $\text{Altura} > 1.80$ E $\text{Peso} < 90$ Então Desnutrido
- Senão Saudável

Interpretação das Regras de Classificação no Espaço



Regras

- Se $\text{Peso} > 130$ Então Obeso
- Se $\text{Peso} > 110$ E $\text{Altura} = \text{"Média"}$ Então Obeso
- Se $\text{Peso} > 90$ E $\text{Altura} = \text{"Baixa"}$ Então Saudável
- Se $\text{Peso} < 90$ E $\text{Altura} = \text{"Alta"}$ Então Desnutrido
- Se $\text{Peso} < 60$ E $\text{Altura} = \text{"Média"}$ Então Desnutrido
- Senão Saudável

Regras de Classificação

- Uma regra R pode ser avaliada por sua cobertura e sua acurácia
- Seja D um conjunto de exemplos rotulados, X um exemplo tal que $X \in D$, $n_{cobertos}$ o número de tuplas que R cobre, $n_{corretos}$ o número de tuplas corretamente classificadas por R , e $|D|$ o número de exemplos em D

$$cobertura(R) = \frac{n_{cobertos}}{|D|} \quad (1)$$

$$acurácia(R) = \frac{n_{corretos}}{n_{cobertos}} \quad (2)$$

Regras de Classificação

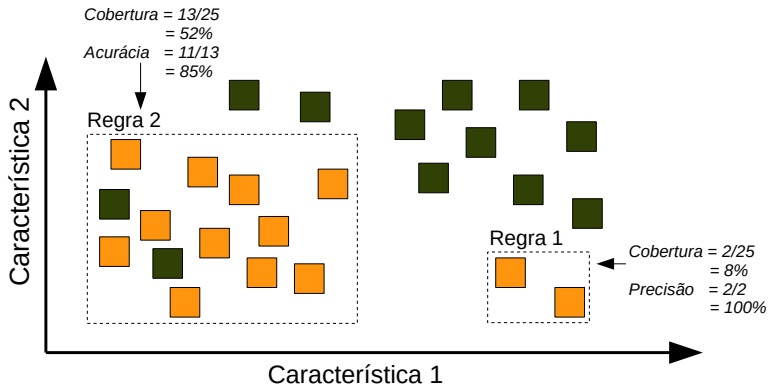


Figura: Acurácia × Cobertura

Regras de Classificação

- Se uma regra é satisfeita por X , a regra é dita ser “disparada”

| Tempo | Temperatura | Umidade | Ventando | <u>Jogar</u> |
|------------|-------------|---------|----------|--------------|
| Ensolarado | Média | Normal | Sim | ??? |



Modelo de Classificação (Regras)

Se Tempo = "Nublado" Então Jogar = "Sim"
 Se Tempo = "Ensolarado" E Umidade = "Alta" Então Jogar = "Não"
 Se Tempo = "Ensolarado" E Umidade = Normal Então Jogar = "Sim"
 Se Tempo = "Chuvoso" E Ventando = Não Então Jogar = "Sim"
 Se Tempo = "Chuvoso" E Ventando = Sim Então Jogar = "Não"



Regras Disparadas

Se Tempo = "Nublado" Então Jogar = "Sim"
 Se Tempo = "Ensolarado" E Umidade = "Alta" Então Jogar = "Não"
 Se **Tempo = "Ensolarado" E Umidade = "Normal"** Então **Jogar = "Sim"**
 Se Tempo = "Chuvoso" E Ventando = "Não" Então Jogar = "Sim"
 Se Tempo = "Chuvoso" E Ventando = "Sim" Então Jogar = "Não"



| Tempo | Temperatura | Umidade | Ventando | <u>Jogar</u> |
|------------|-------------|---------|----------|--------------|
| Ensolarado | Média | Normal | Sim | SIM |

Regras de Classificação

- Se mais de uma regra é disparada, uma estratégia para resolução de conflitos é necessária
 - Ordenação de regra
 - Ordenação baseada em classe: as regras das classes mais frequentes têm maior prioridade, ou as regras que possuem menor erro de classificação por classe
 - Ordenação baseada em regras: as regras são organizadas em listas de prioridades segundo alguma medida de qualidade de regras (como cobertura e acurácia)
 - Ordenação de tamanho
 - Atribui maior prioridade a regra disparada que possui maior tamanho (maior número de testes)

Regras de Classificação

| Tempo | Temperatura | Umidade | Ventando | Jogar |
|---------|-------------|---------|----------|-------|
| Nublado | Baixa | Alta | Sim | ??? |



Modelo de Classificação (Regras)

tempo = nublado & temperatura = baixa & ventando = sim ⇒ jogar = não
 tempo = ensolarado & umidade = alta ⇒ jogar = não
 tempo = ensolarado & umidade = normal ⇒ jogar = sim
 tempo = chuvoso & ventando = não ⇒ jogar = sim
 tempo = chuvoso & ventando = sim ⇒ jogar = não
 tempo = nublado ⇒ jogar = sim



Regras Disparadas

tempo = nublado & temperatura = baixa & ventando = sim ⇒ jogar = não
 tempo = ensolarado & umidade = alta ⇒ jogar = não
 tempo = ensolarado & umidade = normal ⇒ jogar = sim
 tempo = chuvoso & ventando = não ⇒ jogar = sim
 tempo = chuvoso & ventando = sim ⇒ jogar = não
 tempo = nublado ⇒ jogar = sim



| Tempo | Temperatura | Umidade | Ventando | Jogar |
|---------|-------------|---------|----------|-------|
| Nublado | Baixa | Alta | Sim | NÃO |

Foram disparadas duas regras. Porém, se utilizado o critério do tamanho da regra, isto é, a regra mais específica ganha, apenas a primeira é disparada.

Regras de Classificação

- Se nenhuma regra é disparada, uma regra *default* deve ser especificada
 - A classe da regra *default* pode ser a classe majoritária
 - A condição ou antecedente da regra *default* é vazia

| Tempo | Temperatura | Umidade | Ventando | <u>Jogar</u> |
|---------|-------------|---------|----------|--------------|
| Nevando | Baixa | Alta | Sim | ??? |



Modelo de Classificação (Regras)

tempo = nublado & temperatura = baixa & ventando = sim \Rightarrow jogar = não
 tempo = ensolarado & umidade = alta \Rightarrow jogar = não
 tempo = ensolarado & umidade = normal \Rightarrow jogar = sim
 tempo = chuvoso & ventando = não \Rightarrow jogar = sim
 tempo = chuvoso & ventando = sim \Rightarrow jogar = não
 tempo = nublado \Rightarrow jogar = sim
 $\emptyset \Rightarrow$ jogar = sim

A classe SIM é a mais frequente.

| Tempo | Temperatura | Umidade | Ventando | <u>Jogar</u> |
|---------|-------------|---------|----------|--------------|
| Nevando | Baixa | Alta | Sim | SIM |

Regras Disparadas

tempo = nublado & temperatura = baixa & ventando = sim \Rightarrow jogar = não
 tempo = ensolarado & umidade = alta \Rightarrow jogar = não
 tempo = ensolarado & umidade = normal \Rightarrow jogar = sim
 tempo = chuvoso & ventando = não \Rightarrow jogar = sim
 tempo = chuvoso & ventando = sim \Rightarrow jogar = não
 tempo = nublado \Rightarrow jogar = sim
 $\emptyset \Rightarrow$ jogar = sim

Como nenhuma regra anterior a default foi disparada, o exemplo será classificado com a classe majoritária.



Indução de Regras com o Algoritmo de Cobertura Sequencial

- Regras SE-ENTÃO podem ser extraídas diretamente do conjunto de treinamento utilizando um algoritmo de cobertura sequencial
- As regras são aprendidas sequencialmente (uma por vez), na qual cada regra para uma dada classe irá cobrir muitos exemplos de uma classe (e esperançosamente nenhum exemplo de outras classes)

Indução de Regras com o Algoritmo de Cobertura Sequencial

- Existem muitos algoritmos para cobertura sequencial
 - AQ [Michalski, 1969]
 - CN2 [Clark and Niblett, 1989]
 - RIPPER [Cohen, 1996]
 - ...
- Estratégia Geral
 - É aprendida uma regra por vez
 - Cada vez que uma regra é aprendida, os exemplos cobertos pela regra são removidos
 - O processo se repete até que não existam mais exemplos

• Algoritmo: Cobertura Sequencial

• Entrada:

- D : conjunto de exemplos de treinamento
- Atr_vals : conjunto de todos os atributos e seus possíveis valores


• Saída: Conjunto de regras SE-ENTÃO

• Método:

- 1 $Conjunto_Regras = \{\}$
- 2 **para cada** classe c **faça**
- 3 **repita**
- 4 $Regra = \text{Aprenda_Uma_Regra}(D, Atr_vals, c)$
- 5 remova tuplas cobertas por $Regra$ de D
- 6 $Conjunto_Regras = Conjunto_Regras \cup Regra$
- 7 **até** condição de término
- 8 **fim para**
- 9 **retorne** $Conjunto_Regras$

Indução de Regras com o Algoritmo de Cobertura Sequencial


- Tipicamente as regras são aumentadas (adição de testes) de uma forma geral-para-especifica
- Começa-se com uma regra vazia e então gradualmente são atribuídos testes à regra



Indução de Regras com o Algoritmo de Cobertura Sequencial

- Tipicamente, o conjunto de dados irá conter muitos atributos, cada qual podem ter vários valores possíveis
- Encontrar um conjunto de regras ótimas torna-se extremamente custoso
- Ao invés disso, o método *Aprenda_Uma_Regra* adota uma estratégia de busca em profundidade gulosa
 - A cada adição de um teste a uma regra, é adicionado o teste de atributo que melhora a qualidade da regra baseada nos exemplos de treinamento
 - Este processo se repete até que a regra resultante atinja um nível de qualidade aceitável

Indução de Regras com o Algoritmo de Cobertura Sequencial



- O método *Aprenda_Uma_Regra* necessita de uma **medida de qualidade**
 - Acurácia
 - Cobertura
 - Medidas de seleção de atributos utilizado na indução de árvores de decisão

Exemplo

Tabela: Conjunto de dados *Contact Lens*

| Age | Spectable prescription | Astigmatism | Tear production rate | Recommended lenses |
|----------------|------------------------|-------------|----------------------|--------------------|
| young | myope | no | reduced | none |
| young | myope | no | normal | soft |
| young | myope | yes | reduced | none |
| young | myope | yes | normal | hard |
| young | hypermetrope | no | reduced | none |
| young | hypermetrope | no | normal | soft |
| young | hypermetrope | yes | reduced | none |
| young | hypermetrope | yes | normal | hard |
| pre-presbyopic | myope | no | reduced | none |
| pre-presbyopic | myope | no | normal | soft |
| pre-presbyopic | myope | yes | reduced | none |
| pre-presbyopic | myope | yes | normal | hard |
| pre-presbyopic | hypermetrope | no | reduced | none |
| pre-presbyopic | hypermetrope | no | normal | soft |
| pre-presbyopic | hypermetrope | yes | reduced | none |
| pre-presbyopic | hypermetrope | yes | normal | none |
| presbyopic | myope | no | reduced | none |
| presbyopic | myope | no | normal | none |
| presbyopic | myope | yes | reduced | none |
| presbyopic | myope | yes | normal | hard |
| presbyopic | hypermetrope | no | reduced | none |
| presbyopic | hypermetrope | no | normal | soft |
| presbyopic | hypermetrope | yes | reduced | none |
| presbyopic | hypermetrope | yes | normal | none |

- Regra inicial: SE ? ENTÃO recommendation = hard
 - Nove possibilidades

| Regra | Acurácia |
|---------------------------------------|----------|
| age = young | 2/8 |
| age = pre-presbyopic | 1/8 |
| age = presbyopic | 1/8 |
| spectacle prescription = myope | 3/12 |
| spectacle prescription = hypermetrope | 1/12 |
| astigmatism = no | 0/12 |
| astigmatism = yes | 4/12 |
| tear production rate = reduced | 0/12 |
| tear production rate = normal | 4/12 |

- É selecionada a regra com maior acurácia
SE astigmatism = yes ENTÃO recommendation = hard
- A regra possui acurácia de apenas 33,34%
- Refinamento da regra
SE astigmatism = yes & ? ENTÃO recommendation = hard

Tabela: Parte do conjunto de dados *Contact Lens* no qual *astigmatism* = yes

| Age | Spectable prescription | Astigmatism | Tear production rate | Recommended lenses |
|----------------|------------------------|-------------|----------------------|--------------------|
| young | myope | yes | reduced | none |
| young | myope | yes | normal | hard |
| young | hypermetrope | yes | reduced | none |
| young | hypermetrope | yes | normal | hard |
| pre-presbyopic | myope | yes | reduced | none |
| pre-presbyopic | myope | yes | normal | hard |
| pre-presbyopic | hypermetrope | yes | reduced | none |
| pre-presbyopic | hypermetrope | yes | normal | none |
| presbyopic | myope | yes | reduced | none |
| presbyopic | myope | yes | normal | hard |
| presbyopic | hypermetrope | yes | reduced | none |
| presbyopic | hypermetrope | yes | normal | none |

- Considerando as possibilidades para o termo ? tem-se 7 possibilidades

| Regra | Acurácia |
|---------------------------------------|----------|
| age = young | 2/4 |
| age = pre-presbyopic | 1/4 |
| age = presbyopic | 1/4 |
| spectacle prescription = myope | 3/6 |
| spectacle prescription = hypermetrope | 1/6 |
| tear production rate = reduced | 0/6 |
| tear production rate = normal | 4/6 |

- O teste que gera a maior melhora na acurácia é `tear production rate = normal`
SE `astigmatismo = yes` E `tear production rate = normal` ENTÃO `recommendation = hard`
- A acurácia de $4/6 = 67\%$ é uma boa acurácia
- Entretanto podemos continuar e procurar por uma regra com maior acurácia

Tabela: Parte do conjunto de dados *Contact Lens* no qual *astigmatism = yes* e *productionrate = normal*

| Age | Spectable prescription | Astigmatism | Tear production rate | Recomended lenses |
|----------------|------------------------|-------------|----------------------|-------------------|
| young | myope | yes | normal | hard |
| young | hypermetrope | yes | normal | hard |
| pre-presbyopic | myope | yes | normal | hard |
| pre-presbyopic | hypermetrope | yes | normal | none |
| presbyopic | myope | yes | normal | hard |
| presbyopic | hypermetrope | yes | normal | none |

- Regra: SE astigmatism = yes E tear production rate = normal E ? ENTÃO recommendation = hard
- Temos 5 possibilidades

| Regra | Acurácia |
|---------------------------------------|----------|
| age = young | 2/2 |
| age = pre-presbyopic | 1/2 |
| age = presbyopic | 1/2 |
| spectacle prescription = myope | 3/3 |
| spectacle prescription = hypermetrope | 1/3 |

- Como os testes age = young e spectacle prescription = myope possuem a mesma acurácia, escolhemos o teste que possui maior cobertura
SE astigmatism = yes E tear production rate = normal E spectacle prescription = myope ENTÃO recommendation = hard

- A regra encontrada cobre apenas 3 exemplos da classe *hard*
- Os 3 exemplos são então excluídos da base de treinamento e inicia-se o processo de geração de regras novamente
SE ? ENTÃO recommendation = hard
- Uma vez encontradas as regras que cubram todos os exemplos da classe *hard*, repete-se o processo para as demais classes

Exercício


Utilizando o algoritmo de cobertura sequencial, extraia as regras de classificação do conjunto de dados apresentado abaixo. Em seguida, classifique um cliente cujo número de ligações pro SAC e o número de ligações para a mesma operadora é baixo.

| ID | Min. Mesma Op. | Min Outras Op. | Num. Lig. SAC | <u>SAIU</u> <u>OP.</u> |
|----|----------------|----------------|---------------|---------------------------|
| 1 | BAIXA | BAIXA | ALTA | NÃO |
| 2 | ALTA | BAIXA | MEDIA | NÃO |
| 3 | ALTA | BAIXA | BAIXA | NÃO |
| 4 | BAIXA | BAIXA | MEDIA | NÃO |
| 5 | MÉDIA | MEDIA | BAIXA | NÃO |
| 6 | ALTA | MEDIA | ALTA | SIM |
| 7 | BAIXA | ALTA | BAIXA | SIM |
| 8 | ALTA | MEDIA | BAIXA | NÃO |
| 9 | MÉDIA | ALTA | MEDIA | SIM |
| 10 | ALTA | ALTA | BAIXA | SIM |
| 11 | ALTA | MÉDIA | ALTA | SIM |

Atributos Numéricos

- Para cada atributo numérico, as instancias são ordenadas de acordo com os valores dos atributos
- Para cada possível limiar de divisão dos valores, um teste binários (menor que / maior ou igual ao limiar) é criado
- Avaliar a divisão

Atributos Numéricos

| Colesterol | <u>Doente</u> | | Colesterol | <u>Doente</u> |
|------------|---------------|---|------------|---------------|
| 200 | NÃO |  | 200 | NÃO |
| 270 | SIM | | 239 | NÃO |
| 241 | SIM | | 241 | SIM |
| 239 | NÃO | | 270 | SIM |



Testes Possíveis

| Teste | Acurácia (Classe Não) |
|----------|-----------------------|
| < 219,5 | 1/1 |
| >= 219,5 | 1/3 |
| < 240,0 | 2/2 |
| >=240,0 | 0/2 |
| < 255,5 | 2/3 |
| >= 255,5 | 0/1 |

Classificadores Associativos

- A Análise de Associações também pode ser utilizada para a extração de regras de classificação
- Uma das diferenças em relação a Análise de Associações não supervisionada é que o consequente das regras são compostos apenas pelos valores dos atributos alvo
- Regras podem ser ordenadas por medidas objetivas, como confiança ou suporte, ou número de itens no antecedente para definir as prioridades dos disparos das regras
- **LEMBRETE:** todos os valores dos atributos devem ser categóricos

Classificadores Associativos

- Extração de regras de associação na qual o consequente da regra corresponde a uma classe
age = youth & credit = ok \Rightarrow buys computer = yes
[suporte = 20%, confiança = 93%]
- Métodos tradicionais para classificação associativa
 - CBA [Liu et al., 1998]
 - CMAR [Li et al., 2001]
 - CPAR [Yin and Han, 2003]
 - ...

Exercício

Extraia regras de associação para classificação com suporte mínimo de 30% e confiança mínima de 75%. Em seguida, classifique o exemplo cujo número de ligações com outra operadora é alto.

| Min Outras Op. | Num. Lig. SAC | <u>SAIU OP.</u> |
|----------------|---------------|-----------------|
| BAIXA | MEDIA | NÃO |
| BAIXA | MEDIA | NÃO |
| BAIXA | BAIXA | NÃO |
| BAIXA | MEDIA | NÃO |
| MEDIA | BAIXA | NÃO |
| ALTA | ALTA | SIM |
| ALTA | BAIXA | SIM |
| MEDIA | BAIXA | NÃO |
| ALTA | MEDIA | SIM |
| ALTA | BAIXA | SIM |
| MEDIA | ALTA | SIM |

Material Complementar

- DESCOBERTA DE REGRAS DE CLASSIFICAÇÃO UTILIZANDO ANÁLISE FORMAL DE CONCEITOS

[https:](https://www.ppgia.pucpr.br/pt/arquivos/mestrado/dissertacoes/2011/jones_granatyr_final.pdf)

[//www.ppgia.pucpr.br/pt/arquivos/mestrado/dissertacoes/2011/jones_granatyr_final.pdf](https://www.ppgia.pucpr.br/pt/arquivos/mestrado/dissertacoes/2011/jones_granatyr_final.pdf)

- Classificação Associativa Utilizando Seleção e Construção de Regras: um Estudo Comparativo

<https://sites.icmc.usp.br/gbatista/files/enia2007.pdf>

Imagem do Dia

Vc é programador né?? O que vc já desenvolveu??

- Dores
- Doenças
- Stress
- Falta de sono
- Abstinência por café

Inteligência Artificial
<http://lives.ufms.br/moodle/>

Rafael Geraldeli Rossi
rafael.g.rossi@ufms.br

Slides baseados em [Tan et al., 2005]

Referências Bibliográficas I



Clark, P. and Niblett, T. (1989).

The CN2 induction algorithm.

Mach. Learn., 3(4):261–283.



Cohen, W. W. (1996).

Learning trees and rules with set-valued features.

In *Proceedings of the thirteenth national conference on Artificial intelligence - Volume 1*, AAAI'96, pages 709–716.
AAAI Press.

Referências Bibliográficas II



Li, W., Han, J., and Pei, J. (2001).

CMAR: Accurate and efficient classification based on multiple class-association rules.

In Proceedings of the 2001 IEEE International Conference on Data Mining, ICDM '01, pages 369–376, Washington, DC, USA. IEEE Computer Society.



Liu, B., Hsu, W., and Ma, Y. (1998).

Integrating classification and association rule mining.

In Proceedings of the 4th international conference on Knowledge Discovery and Data mining (KDD'98), pages 80–86. AAAI Press.

Referências Bibliográficas III



Michalski, R. (1969).

On the quasi-minimal solution of the general covering problem.

In Proceedings of the 5th International Symposium on Information Processing (FCIP-69), volume A3, pages 125–128.



Tan, P., Steinbach, M., Karpatne, A., and Kumar, V. (2019).
Introduction to Data Mining.

What's New in Computer Science Series. Pearson.



Tan, P.-N., Steinbach, M., and Kumar, V. (2005).
Introduction to Data Mining.
Addison-Wesley.

Referências Bibliográficas IV



Yin, X. and Han, J. (2003).

CPAR: Classification based on predictive association rules.

In *SIAM International Conference on Data Mining*.